

Universidade de Brasília (UnB)

Introdução a inteligência artificial, histórico, estado da arte, benefícios e riscos. Agentes inteligentes, ambientes e racionalidade

Leonardo Henrique Sobral Sauma Junior

RESUMO

A inteligência artificial é um campo interdisciplinar que combina ciência da computação, filosofia, matemática e neurociência para desenvolver sistemas capazes de emular ou superar capacidades humanas. Este trabalho explora a evolução histórica da IA, desde suas raízes na mitologia grega e ficção do século XIX até marcos como a Conferência de Dartmouth (1956) e o desenvolvimento de redes neurais, que impactam nosso cotidiano. São abordados conceitos fundamentais, como agentes racionais, classificação de ambientes e técnicas como deep learning e sistemas especialistas. Além disso, neste trabalho você irá encontrar exemplos práticos sobre PDDL, uma linguagem formal padronizada utilizada em Inteligência Artificial para modelar problemas de planejamento automatizado, que foi utilizada em uma competição real na matéria de Fundamentos Lógicos de Inteligência Artificial.

1. O que é inteligência artificial?

Primeiramente, para contextualizar, devemos ter o entendimento da definição de inteligência. Segundo Aurélio (2025), a inteligência é a habilidade para entender e solucionar adversidades ou problemas, adaptando-se a circunstâncias novas. Com essa informação, temos que o conceito de inteligência artificial é a imitação de máquinas e computadores no quesito resolução de problemas à mente humana. Existem algumas versões nesse contexto, sendo a fidelidade à performance humana ou racionalidade e o raciocínio ou comportamento, havendo então, quatro possibilidades de combinações.

Para compreender melhor essas quatro versões, podemos utilizar o exemplo de um carro autônomo. Se o objetivo for pensar como um humano, o sistema tenta simular o modo como motoristas humanos tomam decisões, considerando emoções, percepções, intuições que estão intrinsecamente ligadas à mente humana. Caso a ideia for agir como um humano, o modo de navegação do carro buscaria um mimetismo às ações humanas, como a direção mais lenta na chuva e, dependendo de como foi treinada, pode agir de forma imprudente, algo que alguns humanos fazem, como buzinar caso o pedestre demore para atravessar a rua. Já no modelo de pensar racionalmente, o foco está em uma busca pela lógica perfeita, calculando rotas mais seguras e eficientes com base em algoritmos. Por fim, ao agir racionalmente, o carro se concentra apenas em alcançar seus objetivos, mesmo que para isso tome decisões que um humano talvez não tomasse.

1.1. Teste de Turing: Agindo de forma humana

Proposto por Alan Turing em 1950, o Teste de Turing surgiu como uma forma para responder à pergunta “As máquinas podem pensar?”. Para uma máquina ser considerada inteligente, seria necessário uma pessoa conversar com uma máquina sem saber que é uma máquina, além de não conseguir distinguir se está falando com uma máquina ou com um humano. Para concluir o teste, a máquina teria que ter um processamento de linguagem natural, para se comunicar com êxito na linguagem humana, além da capacidade de armazenar o que sabe ou ouve, para ter um repertório contextualizado sendo a representação do conhecimento, o raciocínio automatizado para responder perguntas e tirar novas conclusões, o aprendizado de máquina para se adaptar a novas circunstâncias, a visão computacional e o reconhecimento de fala para além de se comunicar, também conseguir entender e, por fim, a robótica para ter a capacidade de se mover ou manipular objetos. A ideia de Turing está medindo apenas a capacidade da inteligência artificial de imitar o comportamento humano em uma conversa, não necessariamente tendo que ter uma consciência, logo, o Teste de Turing acaba sendo limitado.

1.2 Modelagem cognitiva: pensamento de forma humana

A modelagem cognitiva é uma abordagem da Inteligência Artificial que busca replicar os processos mentais humanos, como raciocínio, aprendizado e tomada de decisão. Seu objetivo não é apenas resolver problemas de maneira eficiente, mas sim entender e simular como os humanos pensam. Para isso, é utilizado métodos

como a introspecção (analisar a própria mente), experimentos psicológicos (observar o comportamento de uma pessoa) e captar imagens do cérebro em funcionamento.

1.3 Leis do pensamento: pensando racionalmente

Inspirada no silogismo de Aristóteles, a abordagem de pensamento racional se baseia na lógica formal e na matemática para criar sistemas que raciocinam de forma rigorosa. Utiliza ferramentas como lógica e probabilidade, permitindo lidar com afirmações condicionais e incertezas. Contudo, o pensamento racional não gera um comportamento inteligente, pois está embasado apenas na ação racional, não conseguindo interpretar sarcasmos por exemplo.

1.4 Agente racional: agindo racionalmente

Um agente racional é um sistema autônomo que percebe seu ambiente, processa informações, além de adaptar-se a mudanças e agir para maximizar suas chances de sucesso, mesmo sob incerteza, atingindo o melhor resultado esperado. Comparado às abordagens comentadas anteriormente, o agente racional é considerado mais geral e mais suscetível ao desenvolvimento científico.

1.5 Modelo padrão

O agente racional é a abordagem de maior relevância no âmbito de pesquisa e desenvolvimento. A inteligência artificial teve seu foco estabelecido em construir agentes que fazem a “coisa certa”, porém surgem dois tópicos importantes para serem debatidos (i) a definição de “coisa certa” e (ii) como escolher corretamente o objetivo do agente. Atualmente está cada vez mais difícil escolher um objetivo bem definido que resolva um problema real para a máquina.

2. Fundamentos da inteligência artificial

A inteligência artificial é um campo interdisciplinar, abordando áreas além da ciência da computação. Em seus pilares de apoio, existe o campo da filosofia, que levanta questionamentos relevantes para a área como “de onde vem o conhecimento?” e “como o conhecimento leva à ação?”. Além da filosofia, outra área de grande acordo com a IA é a matemática, usando essa forte ferramenta ao seu favor, com lógicas e estatística, além de levantar o questionamento sobre informações incertas. A economia é de fundamental importância para a tomada de decisão de acordo com preferências além de pensar em como fazer isso quando a recompensa está em um futuro distante. Já a neurociência inspira arquiteturas como redes neurais artificiais, que visam imitar o funcionamento do cérebro para reconhecer padrões em imagens ou traduzir idiomas, por exemplo. A área da psicologia vem para entender como os seres humanos e animais pensam e tomam decisões. A ciência da computação vem para fazer a ligação entre as outras áreas, juntando a teoria com a prática. Na cibernética é a porção que lida com o funcionamento de artefatos físicos operados pela inteligência artificial, como exemplo uma perna robótica que consegue lidar com diferentes tipos de relevo,

mantendo uma postura e equilíbrio adequados. Por fim, a linguística surge para fomentar a dúvida sobre como a linguagem se relaciona com o pensamento.

3. Histórico da inteligência artificial

É de pensamento por grande parte da população que a inteligência artificial é algo recente, isso se deve pela grande ascensão que a IA está tomando nos dias atuais, porém há registros de ideais da Grécia Antiga que podem ser relacionados aos conceitos mais modernos de uma inteligência não natural. Na ficção é outra área onde se torna mais comum encontrar pensamentos “fora da caixa” que encaixam perfeitamente ao tópico de inteligência não humana.

3.1 Mitologia e ficção

3.1.1 Mitologia Grega: Talos e Ilíada

Talos (400 A.C.) é um grande exemplo notável na mitologia, ele era um gigante de bronze autônomo com uma inteligência não humana, realizava voltas pela ilha de Creta e atacava invasores que apareciam. Ainda na mitologia grega, temos o poema Ilíada, feito por Homero (século IX A.C.), o deus ferreiro Hefesto é descrito como um criador de autômatos, sendo seres de ouro com aparência humana que ajudavam em seu trabalho, podendo se comunicar, entender ordens e se mover sozinhos, já nessa época tendo uma referência a uma forma de consciência ou programação embutida em seres. Esses exemplos revelam um desejo, desde a antiguidade de criar máquinas que façam além de executar tarefas, mas que também se parecessem com seres vivos em diversos aspectos.

3.1.2 The Invisible Boy (1957)

Trazendo para o contexto de ficção, temos o filme The Invisible Boy (1957), que narra a história de um supercomputador capaz de manipular um garoto para executar seus planos de dominação do mundo. A visão tratada pelo filme é interessante pois reflete a ideia que a tecnologia pode amplificar não apenas o lado bom, mas também vícios humanos. Apesar do filme ser considerado antigo, produzido na década de 50, ele já consegue trazer um debate sobre a autonomia máquina-humano e a ética na programação de sistemas inteligentes.

3.1.3 Erewhon (1872)

Escrito por Samuel Butler em 1872, Erewhon é uma obra que antecipou debates sobre inteligência artificial e autonomia tecnológica décadas antes da computação moderna. No capítulo “O Livro das Máquinas”, o autor explora uma sociedade fictícia que, após perceber o potencial que as máquinas conseguem evoluir, decide destruí-las para evitar serem dominados por suas próprias criações. Embora Butler não utilize o termo “inteligência artificial”, a sua visão sobre máquinas como entidades evolutivas influenciou pensadores como Alan Turing, que fez menção à obra em seu próprio artigo “Intelligent Machinery, A Heretical Theory”. Além disso, influenciou obras como R.U.R (1920), de Karel Čapek, que cunhou a palavra “robô”.

3.1.4 Outras obras

A ficção continuou a explorar a inteligência não humana através de obras icônicas. Frankenstein (1818), de Mary Shelley, introduziu a angústia ética de criar vida artificial, antecipando dilemas como a responsabilidade do criador sobre suas criaturas autônomas. Já o ensaio Darwin among the Machines (1863), também de Samuel Butler, propôs que máquinas poderiam evoluir por seleção natural, substituindo humanos, uma ideia precursora da singularidade tecnológica. O filme Metropolis (1927) trouxe o robô Maria, criado para manipular massas, simbolizando o medo de que a tecnologia amplifique a desumanização. Por fim, Jogos de Guerra (1983) questionou os limites da IA em decisões críticas, levantando o questionamento de como diferenciar a realidade do mundo virtual além do debate sobre a influência da inteligência artificial em decisões críticas, como iniciar uma guerra. Juntas, essas obras ilustram como a ficção, desde muito tempo, tem sido um laboratório para antecipar riscos e possibilidades da IA, equilibrando o encanto do avanço tecnológico com alertas sobre autonomia e ética.

3.2 História da inteligência artificial

3.2.1 O início da inteligência artificial (1943-1956)

O surgimento da Inteligência Artificial como campo científico teve raízes em contribuições pioneiras que uniram neurociência, matemática e computação. Em 1943, Warren McCulloch e Walter Pitts propuseram um modelo matemático de neurônios artificiais, onde cada unidade podia estar “ligada” ou “desligada”, ativando-se apenas se recebesse estímulo suficiente de neurônios vizinhos. Esse modelo permitia replicar conectivos lógicos (AND, OR, NOT) em redes simples, sugerindo que sistemas neurais poderiam, em tese, aprender e processar informações.

Em 1949, Donald Hebb avançou essa ideia com a aprendizagem Hebbiana, uma regra que ajustava a força das conexões entre neurônios com base na frequência de ativação simultânea, princípio fundamental para redes neurais modernas. Na década de 1950, Marvin Minsky e Dean Edmonds materializaram esses conceitos ao construir o SNARC, o primeiro computador baseado em redes neurais, usando 3.000 válvulas para simular 40 neurônios.

Paralelamente, Alan Turing introduziu ideias revolucionárias. Além do Teste de Turing (1950), que propôs um critério para avaliar a inteligência de máquinas, ele discutiu aprendizado de máquina, algoritmos genéticos e aprendizado por reforço, argumentando que ensinar máquinas a aprender seria mais eficaz do que programá-las manualmente.

O marco definitivo ocorreu em 1956, com a Conferência de Dartmouth, organizada por John McCarthy e Marvin Minsky. Reunindo pesquisadores como Claude Shannon e Herbert Simon, o evento consolidou a IA como disciplina e cunhou o termo “Inteligência Artificial”. A conferência estabeleceu a ambição de criar

sistemas capazes de simular todas as áreas da inteligência humana, pavimentando o caminho para as décadas seguintes de pesquisa.

3.2.2 Entusiasmo inicial e grandes expectativas (1952-1969)

O período entre 1952 e 1969 foi marcado por otimismo e avanços práticos que solidificaram a IA como campo promissor. Em 1959, Herbert Gelernter desenvolveu o Provisor do Teorema da Geometria, um sistema capaz de demonstrar teoremas complexos, rivalizando com a capacidade de estudantes universitários. Essa conquista mostrou que máquinas podiam lidar com raciocínio lógico e matemático, um marco para a automatização de processos intelectuais.

Na mesma década, Arthur Samuel inovou ao aplicar aprendizado por reforço em um programa de damas. Seu algoritmo aprendia com partidas anteriores, melhorando estrategicamente até alcançar nível amador avançado. Esse foi um dos primeiros exemplos de máquinas que aprendiam com experiência, um princípio central da IA moderna.

Para simplificar desafios complexos, pesquisadores adotaram problemas de micro-mundo, como o blocks world, onde robôs simulados manipulavam blocos virtuais. Esses ambientes controlados permitiam testar habilidades de planejamento e raciocínio espacial, fundamentais para desenvolver sistemas mais versáteis.

As redes neurais, teorizadas por McCulloch e Pitts em 1943, ganharam forma prática com os Perceptrons de Frank Rosenblatt (1962). Esses modelos simplificados de neurônios artificiais eram capazes de classificar padrões, como distinguir letras em imagens, alimentando a crença de que redes neurais poderiam emular a aprendizagem humana.

3.2.3 Uma dose de realidade (1966-1973)

O otimismo inicial da IA deu lugar a um período de revisão crítica entre 1966 e 1973, quando as limitações técnicas e teóricas do campo se tornaram evidentes. Embora sistemas como os Perceptrons (redes neurais de camada única) fossem eficazes para problemas simples (ex: classificar formas geométricas básicas), falhavam em tarefas mais complexas.

Em 1969, Marvin Minsky e Seymour Papert publicaram o livro “Perceptrons”, demonstrando matematicamente que essas redes só podiam resolver problemas linearmente separáveis. O emblemático problema da porta XOR, que exige reconhecer padrões não lineares, expôs essa fraqueza, um Perceptron não conseguia aprender a relação XOR, essencial para muitos desafios do mundo real.

Essa limitação, somada à incapacidade de sistemas da época de lidar com ambiguidades ou contextos dinâmicos, desencadeou o primeiro “inverno da IA”, sendo um período de ceticismo, corte de financiamentos e redução de interesse na área. Críticos argumentavam que a IA estava longe de cumprir suas promessas iniciais, especialmente em tarefas como compreensão de linguagem natural ou raciocínio abstrato. Esse período forçou uma reorientação na pesquisa. Em vez de buscar “inteligência geral”, cientistas focaram em domínios específicos, como sistemas especialistas, que ganharam destaque na década de 1980. O Inverno da

IA serviu como um alerta sobre os riscos da supervalorização tecnológica, incentivando abordagens mais pragmáticas e interdisciplinares. Paradoxalmente, essa fase de crítica foi essencial para o ressurgimento da IA nas décadas seguintes, agora com bases mais sólidas em probabilidade, aprendizado estatístico e arquiteturas de redes neurais multicamadas.

3.2.4 Sistemas Especialistas (1969-1986)

A partir do final da década de 1960, a Inteligência Artificial encontrou um novo rumo ao abandonar a busca por sistemas de propósito geral e adotar uma abordagem pragmática, os sistemas especialistas. Esses programas eram projetados para resolver problemas específicos em domínios restritos, combinando bases de conhecimento (regras e dados especializados) com mecanismos de inferência. Um dos primeiros exemplos foi o DENDRAL (1969), desenvolvido por Ed Feigenbaum, Bruce Buchanan e Joshua Lederberg, que revolucionou a química orgânica ao inferir estruturas moleculares a partir de dados de espectrometria de massa, auxiliando pesquisadores em análises complexas. Na medicina, o MYCIN (1970) destacou-se ao diagnosticar infecções sanguíneas com precisão comparável a especialistas humanos, utilizando 450 regras lógicas, se tornando um marco para a aplicação prática de IA em saúde.

O sucesso comercial chegou com o R1 (1982), sistema utilizado pela Digital Equipment Corporation para configurar pedidos de computadores, economizando US\$ 40 milhões anuais e impulsionando a indústria de IA. Entre 1980 e 1988, o mercado cresceu de alguns milhões para bilhões de dólares, com empresas investindo em robótica, visão computacional e hardware especializado. No entanto, os sistemas especialistas enfrentaram limites críticos, sua dependência de regras rígidas os tornava incapazes de lidar com incertezas, como por exemplo sintomas médicos ambíguos, ou aprender com novos dados, exigindo atualizações manuais. Além disso, promessas exageradas de substituição de profissionais humanos, como advogados ou engenheiros, criaram expectativas irreais para época.

Essas fragilidades, somadas à complexidade de manter bases de conhecimento em domínios amplos, levaram ao segundo inverno da IA a partir de 1987. Investidores retiraram recursos, e startups fecharam em massa.

3.2.5 O retorno das redes neurais (1986-presente)

Após décadas de ceticismo durante os “invernos da IA”, as redes neurais ressurgiram na década de 1980 como uma força transformadora, impulsionadas por avanços teóricos e técnicos. Por volta dos anos 1980, pesquisadores como David Rumelhart, Geoffrey Hinton e outros redescobriram o algoritmo de retropropagação, originalmente concebido nos anos 1960, mas negligenciado devido a limitações computacionais. Esse método permitia ajustar os pesos das conexões em redes neurais multicamadas, resolvendo problemas não lineares como o XOR, que havia derrubado os Perceptrons décadas antes. A retropropagação tornou possível treinar modelos complexos para reconhecer padrões em dados reais, como imagens, sons

e textos, marcando a transição de sistemas baseados em regras rígidas para modelos adaptativos e aprendizes.

Os modelos conexionistas (redes neurais) destacaram-se por sua capacidade de formar representações internas dos dados, criando abstrações hierárquicas que refletiam estruturas do mundo real. Por exemplo, em reconhecimento de imagem, camadas ocultas aprendiam a identificar bordas, formas e objetos complexos de forma automática, sem intervenção humana explícita.

3.2.6 Raciocínio probabilístico e aprendizado de máquina (1987-presente)

Como dito no tópico anterior, a partir da década de 1980, a inteligência artificial passou por uma transformação paradigmática, abandonando a rigidez da computação simbólica e abraçando métodos probabilísticos e estatísticos. Esse movimento foi impulsionado pela crítica de pesquisadores como David McAllester (1998), que apontou o isolamento da IA clássica de campos como teoria da informação e otimização.

Nos anos 1980, Cadeias de Markov ocultas se tornaram a base para problemas de reconhecimento de fala, permitindo modelar sequências temporais e ambiguidades linguísticas. Em 1988, Judea Pearl revolucionou o campo com redes Bayesianas, estruturas gráficas que representavam conhecimento incerto e permitiam inferência probabilística eficiente. No mesmo ano, Rich Sutton introduziu Processos de decisão de Markov e formalizou o aprendizado por reforço, onde agentes aprendem políticas ótimas através de tentativa e erro em ambientes dinâmicos.

A unificação gradual de subcampos, como visão computacional, robótica e processamento de linguagem natural, consolidou a IA como disciplina interdisciplinar. Sistemas multiagentes, por exemplo, combinavam subcampos como visão computacional, robótica, reconhecimento de fala, sistemas multiagentes e processamento de linguagem natural. Hoje, o raciocínio probabilístico e o aprendizado de máquina são pilares da IA moderna. Técnicas como redes neurais Bayesianas e modelos generativos, como o GPT-4, demonstram que a incerteza não é um obstáculo, mas uma dimensão a ser explorada.

3.2.7 Big Data (2001-presente)

O século XXI marcou a ascensão da era do Big Data, impulsionada por avanços exponenciais no poder de computação, armazenamento em nuvem e a expansão da World Wide Web. A capacidade de coletar, processar e armazenar conjuntos de dados massivos redefiniu os limites da Inteligência Artificial, sendo eles por exemplo trilhões de palavras em textos, bilhões de imagens, horas de vídeo, registros genômicos, rastreamento de veículos e fluxos contínuos de redes sociais. A disponibilidade de dados nessa grande escala permitiu o desenvolvimento de algoritmos de aprendizado de máquina especialmente projetados para explorar volumes imensos de informação. Técnicas como deep learning, que demandam milhões de exemplos para treinamento, floresceram.

3.2.8 Deep learning (2011-presente)

Embora conceitos básicos sobre aprendizagem profunda existissem desde os anos 1970, foi apenas após 2011 que avanços em poder computacional, algoritmos e disponibilidade de dados permitiram seu maior crescimento e desenvolvimento. A virada decisiva ocorreu em 2012, quando uma rede neural convolucional desenvolvida por Alex Krizhevsky, Ilya Sutskever e Geoffrey Hinton (Universidade de Toronto) venceu a competição ImageNet, reduzindo a taxa de erro em classificação de imagens de 26% para 15%, um salto sem precedentes que validou o potencial das redes profundas. A partir daí, o deep learning dominou aplicações críticas. Em reconhecimento de fala, sistemas como o Google Voice Search atingiram precisão quase humana. Na tradução automática, modelos baseados em redes neurais substituíram abordagens estatísticas tradicionais, produzindo traduções mais fluidas e contextualizadas.

4. O estado da arte em IA

O cenário atual da Inteligência Artificial é definido por avanços tecnológicos sem precedentes e por desafios éticos e sociais complexos, como destacam relatórios como o Stanford University's One Hundred Year Study on AI (AI100) e análises como as de Stone et al. (2016) e Grosz e Stone (2018). O AI Index documenta métricas críticas, sendo elas a capacidade computacional, que dobrou a cada 3,4 meses (superando a Lei de Moore), os investimentos globais em IA que ultrapassaram US\$ 100 bilhões em 2023, e o número de publicações científicas na área cresceu exponencialmente. No entanto, o relatório AI100 alerta que a sociedade está em um ponto de inflexão, a implantação de IA deve ser guiada por valores democráticos como liberdade, igualdade e transparência, evitando riscos como vigilância massiva, discriminação algorítmica e erosão da privacidade.

4.1 AI Index

4.1.1 Publicações (2018-2019)

Os relatórios do AI Index entre 2018 e 2019 revelaram um crescimento exponencial na produção acadêmica em IA, o número de publicações anuais aumentou 20 vezes entre 2010 e 2019, saltando de cerca de 1.000 para mais de 20.000 artigos por ano. As áreas predominantes foram machine learning (aprendizado de máquina), computer vision (visão computacional) e natural language processing (processamento de linguagem natural), que juntas representaram mais de 60% dos estudos. Esse crescimento reflete não apenas avanços técnicos, mas também a priorização de temas com aplicações imediatas, como reconhecimento facial, tradução automática e chatbots.

4.1.2 Estudantes (2018-2019)

Os relatórios do AI Index entre 2018 e 2019 destacaram um crescimento explosivo no interesse acadêmico pela Inteligência Artificial. Nos Estados Unidos, as matrículas em disciplinas de IA quintuplicaram, enquanto internacionalmente, fora dos EUA, o aumento foi 16 vezes maior, refletindo a globalização do campo. A IA

consolidou-se como a especialização mais popular em ciência da computação, atraindo estudantes motivados por aplicações inovadoras em áreas como saúde, robótica e finanças. Existe uma diversidade de gêneros no campo de trabalho da IA, sendo 80% composto por homens e 20% de mulheres.

O entusiasmo pelo campo também se refletiu na participação em conferências. A NeurIPS registrou aumento de 800% no número de participantes desde 2012, enquanto outras conferências tiveram crescimento médio de 30%. Esse fenômeno ilustra não apenas a centralidade do aprendizado de máquina, mas também a atração de investidores, startups e governos para eventos que definem tendências tecnológicas.

4.1.3 Mercado (2018-2019)

Os relatórios do AI Index entre 2018 e 2019 destacaram uma transformação significativa no mercado de trabalho global relacionado à inteligência artificial. Países como Cingapura, Brasil, Austrália, Canadá e Índia emergiram como líderes em crescimento de contratações na área, impulsionados por políticas governamentais de incentivo à inovação, investimentos em educação técnica e demanda por soluções locais em setores como agronegócio, saúde e finanças. No Brasil, por exemplo, startups de fintechs e empresas de logística adotaram IA para otimizar rotas e análise de crédito, enquanto a Índia viu expansão em centros de pesquisa e desenvolvimento de multinacionais. Nos Estados Unidos, o ecossistema de startups de IA explodiu, com um aumento de 20 vezes no número de empresas entre 2010 e 2019.

4.1.4 Desempenho (2018-2019)

Os relatórios do AI Index entre 2018 e 2019 documentaram avanços revolucionários no desempenho de sistemas de IA, consolidando sua superioridade em tarefas específicas. Na visão computacional, a taxa de erro em detecção de objetos caiu de 28% em 2010 para 2% em 2017, superando a precisão humana. Em respostas a perguntas baseadas em imagens, a precisão saltou de 55% para 68%, aproximando-se da marca humana, de 83%. A velocidade de treinamento também evoluiu drasticamente, o tempo necessário para treinar modelos de reconhecimento de imagem reduziu-se 100 vezes em dois anos, graças a otimizações algorítmicas e hardware especializado.

Em 2019, sistemas de IA igualaram ou superaram humanos em jogos como xadrez, go, poker, StarCraft II, Dota 2 e Quake III. Além disso, teve impacto também na área da saúde, conseguindo detectar o câncer de pele e de câncer de próstata.

4.1.5 Viés Algorítmico e Justiça Social: Casos Reais e Impactos Discriminatórios

Apesar dos avanços técnicos, sistemas de inteligência artificial têm reproduzido e amplificado discriminações estruturais, revelando desafios profundos em justiça social. Esses vieses surgem de dados desbalanceados, escolhas

algorítmicas inadequadas ou falta de diversidade nas equipes de desenvolvimento. Como exemplo, temos o caso de reconhecimento facial, em um estudo feito pela Gender Shades (2018), mostrou que sistemas da IBM e Microsoft tinham taxas de erro de até 34% para rostos de mulheres negras, contra menos de 1% para homens brancos.

5. O que a IA pode fazer hoje?

A Inteligência Artificial evoluiu para uma ferramenta multifacetada, com aplicações que abrangem desde tarefas cotidianas até desafios científicos complexos.

5.1 Auxílio à professores na correção de provas

A aplicação da inteligência artificial no ambiente educacional tem promovido avanços significativos na automatização de tarefas rotineiras, permitindo que professores concentrem seus esforços em atividades pedagógicas mais estratégicas. Um dos campos que mais tem se beneficiado dessa evolução é a correção de provas e exercícios com questões de múltipla escolha.

A seguir, é apresentado um vídeo no qual uma professora utiliza seu celular para corrigir provas com o auxílio de IA, apenas apontando a câmera para os gabaritos preenchidos pelos alunos. A tecnologia empregada interpreta as respostas, compara com o gabarito oficial e retorna o resultado instantaneamente.

[Acesse o vídeo clicando aqui.](#)

5.2 Locomoção e robótica avançada

A IA revolucionou a robótica com sistemas capazes de navegar em ambientes complexos e executar tarefas físicas. Robôs como o BigDog e Atlas, desenvolvidos pela Boston Dynamics, demonstram habilidades impressionantes, podem caminhar em terrenos irregulares, carregando cargas pesadas e recuperam o equilíbrio após quedas, sendo aplicados em missões de resgate e operações logísticas.

5.3 Tradução e interação humano-máquina

A IA domina a tradução automática de 99% das línguas humanas, com desempenho próximo ao humano em idiomas como inglês e francês, mesmo quando a tradução não é perfeita ela consegue transmitir a compreensão. Plataformas como o Skype Translator convertem conversas em tempo real para 10 idiomas, enquanto assistentes virtuais como Alexa e Google Assistant respondem a comandos de voz, integrando-se a dispositivos inteligentes.

5.4 Recomendações personalizadas

Empresas como Netflix, Spotify e Amazon utilizam algoritmos de aprendizado de máquina para prever preferências com base em histórico de uso. Esses sistemas

analisam desde textos e músicas até padrões de compra, refinando recomendações continuamente.

5.5 Jogos e Entretenimento

A IA superou campeões humanos em jogos que exigem estratégia, como Go, poker e Dota 2. Em 2022, uma obra de arte gerada por IA venceu uma competição de belas artes, desafiando noções tradicionais de criatividade. Esses feitos não apenas comprovam a capacidade de resolução de problemas, mas também expandem o papel da IA no entretenimento e na cultura, além de levantar questionamentos éticos.

5.6 Geração de vídeos a partir de prompts

A geração de vídeos por meio de Inteligência Artificial tem se consolidado como uma das áreas de maior avanço nos últimos anos, refletindo o rápido progresso dos modelos generativos multimodais. A partir de descrições textuais simples, sistemas baseados em IA são capazes de sintetizar vídeos realistas, com movimentos, expressões faciais e até sincronização labial relativamente coerente com falas geradas artificialmente.

A seguir, é apresentado um vídeo comparativo entre dois cliques gerados com o mesmo prompt “Will Smith comendo macarrão”, sendo um criado em março de 2023 e outro em abril de 2025. A comparação evidencia não apenas o salto técnico em fidelidade visual, mas também o avanço na coerência narrativa e na integração de elementos como iluminação, textura e expressividade facial.

[Acesse o vídeo clicando aqui.](#)

5.7 Gerenciamento de Múltiplas Contas em Redes Sociais com IA

O gerenciamento automatizado de perfis em redes sociais por meio de Inteligência Artificial tem se mostrado uma prática crescente, especialmente em países como a China, onde a presença digital desempenha um papel central tanto em estratégias de marketing quanto em políticas de comunicação pública e privada.

A seguir, é apresentado um vídeo que documenta essa prática, com a inteligência artificial gerenciando 50 contas ao mesmo tempo na rede social X.

[Acesse o vídeo clicando aqui.](#)

5.8 Planejamento com PDDL em jogos de lógica (Light Up / Akari)

O Planejamento baseado em IA, particularmente com uso de PDDL (Planning Domain Definition Language), tem ganhado destaque por sua capacidade de resolver problemas complexos em ambientes com regras bem definidas. Uma aplicação interessante dessa abordagem é em jogos de lógica, como o Light Up, um puzzle no qual o jogador deve posicionar lâmpadas de forma a iluminar todas as células de um grid, respeitando restrições específicas.

Nesse contexto, a IA atua modelando o problema do jogo como um domínio de planejamento: as regras do jogo são traduzidas para ações, estados e restrições em PDDL. A partir dessa modelagem, um planejador automático é capaz de explorar diferentes sequências de ações até encontrar uma solução válida ou comprovar sua inexistência. Essa abordagem é especialmente eficiente para puzzles de média e alta complexidade, nos quais a resolução por tentativa e erro seria inviável.

Desenvolvi um código em Python para uma competição no curso de Fundamentos Lógicos de Inteligência Artificial, lecionada pelo professor Bruno Ribas. O código recebe como entrada um mapa do jogo Light Up e converte automaticamente a estrutura do puzzle para o formato PDDL. Em seguida, o código executa um planejador compatível, como o Madagascar ou Fast Downward (dependendo da categoria da competição), e retorna a sequência de posicionamentos das lâmpadas que resolvem o desafio.

A seguir está o link do repositório do GitHub, nele é possível encontrar mais informações sobre o problema, a competição, exemplos de mapas dos mais fáceis aos mais complexos (que uma pessoa demoraria horas e até dias para resolver), além de encontrar um vídeo explicando detalhadamente como o código funciona tanto por mim quanto pelo professor Bruno Ribas.

[Clique aqui para acessar o repositório.](#)

6. Agente e ambiente

6.1 Ação de um agente

Um agente artificial toma decisões com base em sua programação interna e na sequência de percepções que recebeu do ambiente até o momento. Isso significa que suas ações são determinadas exclusivamente pelo que ele já observou, sem considerar informações não percebidas. Por exemplo, um robô aspirador decide se deve limpar um cômodo com base em sensores que detectam sujeira, mas ignora áreas fora de seu alcance de percepção. Essa limitação intencional garante que o agente opere dentro de parâmetros previsíveis e seguros.

6.2 Função de um agente

A função do agente é um mapeamento abstrato que transforma qualquer sequência histórica de percepções em uma ação específica. Essa função é teórica, definindo o que o agente deve fazer, mas não como implementar. Por exemplo, um agente que joga xadrez usa sua função para escolher movimentos baseados em jogadas anteriores, sem “pensar” em estratégias fora do escopo percebido.

6.3 Programa agente

O programa do agente é a implementação prática da função, traduzindo-a em código executável. Enquanto a função é uma descrição matemática ("se detectar obstáculo, desvie"), o programa define os passos técnicos para isso, como exemplo algoritmos de pathfinding como A*. Agentes podem ser simples, como termostatos que ligam o ar-condicionado ao detectar temperatura alta, ou complexos, como carros autônomos que integram visão computacional e aprendizado por reforço.

7. Racionalidade

A racionalidade em inteligência artificial refere-se à capacidade de um agente tomar decisões que maximizem sua eficácia, considerando as informações disponíveis e os objetivos definidos. Essa racionalidade não é absoluta, mas depende de quatro fatores interconectados: a medida de desempenho, que define critérios de sucesso, como minimizar acidentes em um carro autônomo; o conhecimento prévio do agente sobre o ambiente, por exemplo, mapas ou regras de segurança; as ações disponíveis que ele pode executar, como acelerar ou frear; e a sequência de percepções capturadas até o momento da decisão, dados de sensores ou entradas de usuários. Um agente racional, portanto, não busca a perfeição, mas escolhe a ação que, com base nas evidências e no conhecimento acumulado, oferece a melhor expectativa de resultado.

A distinção entre racionalidade e perfeição é crucial. Enquanto a perfeição exigiria resultados impecáveis em todas as situações, como um sistema de tradução que nunca comete erros, a racionalidade lida com a realidade imperfeita.

Para ser considerado verdadeiramente inteligente, um agente deve ir além da racionalidade momentânea e incorporar três dimensões: aquisição de informações e exploração, tomada de decisão e aprendizado. Juntas, essas capacidades transformam agentes em entidades autônomas e evolutivas, capazes de enfrentar desafios que vão desde a otimização de rotas logísticas até a interação natural com humanos.

8. Especificando o ambiente de tarefas

Projetar um agente eficaz exige uma especificação detalhada do ambiente em que ele atuará, utilizando a estrutura PEAS (Performance, Environment, Actuators, Sensors). A medida de desempenho define o critério de sucesso, por exemplo em um sistema de diagnóstico médico, a precisão ao identificar doenças, em um assistente virtual, o tempo de resposta e a satisfação do usuário. O ambiente descreve o contexto operacional, que pode ser estático, como um tabuleiro de xadrez ou dinâmico como o trânsito urbano, acessível com informações completas ou parcialmente observável como um jogo de pôquer. Os atuadores são os mecanismos que o agente usa para interagir, motores em robôs, alto-falantes em assistentes de voz ou interfaces gráficas em sistemas de recomendação. Já os sensores capturam dados do ambiente, como exemplo em câmeras de veículos autônomos, microfones em dispositivos de reconhecimento de fala ou sensores térmicos em sistemas de segurança.

8.1 Propriedades do Ambiente de Tarefas

A classificação do ambiente de tarefas é fundamental para o projeto de agentes de IA, pois define os desafios e as estratégias necessárias. Um ambiente pode ser totalmente observável, parcialmente observável ou não observável. Pode envolver um agente único ou multiagente. Pode ser determinístico ou não determinístico, episódico ou sequencial, estático ou dinâmico, discreto ou contínuo além disso conhecido ou desconhecido.

9. Benefícios e riscos

A inteligência artificial traz transformações profundas para a sociedade, oferecendo oportunidades significativas, mas também apresentando desafios críticos que exigem atenção e regulamentação.

9.1 Benefícios da IA

Conforme visto durante esse trabalho, podemos chegar à conclusão que a IA otimiza processos em escala global, automatizando tarefas repetitivas e aumentando a eficiência em setores como logística, saúde e finanças. É considerada uma arma poderosa e pode ser utilizada e adaptada para diversas outras áreas.

9.2 Riscos da IA

A IA também introduz riscos complexos. O viés algorítmico em sistemas de reconhecimento facial ou contratação perpetua desigualdades, como demonstrado em casos onde minorias foram injustamente prejudicadas. A perda de privacidade surge com a coleta massiva de dados, enquanto a automação de empregos ameaça profissões tradicionais, ampliando disparidades socioeconômicas.